

Τεχνική Αναφορά Εργασίας

Gas Sensor Array Temperature Modulation (UCI ML Repository)

Πανεπιστήμιο Πειραιώς
Τμήμα Πληροφορικής

Φοιτητής: Μάρκος Κοντούλης
ΑΜ: Π22074

Ημερομηνία: 20/01/2026

Πίνακας Περιεχομένων

Πίνακας Περιεχομένων	2
Περίληψη	3
1. Preprocessing and Data Understanding (Apache Spark)	3
1.1 Dataset και ανάγνωση	3
1.2 Ανακατασκευή και κανονικοποίηση timestamp	3
1.3 Έλεγχοι ποιότητας, ελλείπουσες τιμές και ακραίες τιμές	3
1.4 Οπτικοποιήσεις κατανομών	4
1.5 PySpark ζητούμενα (i)–(v)	7
2. Feature Engineering (pandas).....	8
2.1 Δημιουργία νέων χαρακτηριστικών.....	8
2.2 Σχέση r_mean14 και co_roll_25m (25 λεπτά)	8
3. Temporal Analysis.....	9
3.1 STL decomposition	9
3.2 ACF / PACF στα υπολείμματα	9
3.3 Έλεγχος στασιμότητας (ADF)	10
4. Machine Learning Model Training	11
4.1 Πρόβλημα και διαχωρισμός δεδομένων	11
4.2 Spark MLlib μοντέλα (Linear Regression & Random Forest)	11
4.3 Ενδεικτικές οπτικοποιήσεις (True vs Predicted).....	12
4.4 RNN μοντέλο (GRU).....	12
4.5 Συζήτηση και σύγκριση	13
Παράρτημα — Αρχεία Παραδοτέου.....	14

Περίληψη

Στη συγκεκριμένη αναφορά καλύπτεται όλη η ροή επεξεργασίας και ανάλυσης δεδομένων που παράχθηκαν από 14 αισθητήρες MOX σε πλατφόρμα ανίχνευσης χημικών ουσιών. Περιγράφονται: (i) προεπεξεργασία/κατανόηση δεδομένων με Apache Spark, (ii) παραγωγή νέων features σε pandas, (iii) ανάλυση time series με STL, ACF/PACF και ADF, και (iv) εκπαίδευση/αξιολόγηση μοντέλων πρόβλεψης 1 βήματος (5 λεπτά) με Spark MLlib (Linear Regression, Random Forest) και με RNN (GRU).

1. Preprocessing - Data Understanding (Apache Spark)

1.1 Dataset

Τα δεδομένα βρίσκονται σε αρχεία CSV όπου κάθε εγγραφή περιλαμβάνει τον χρόνο (time_s), την συγκέντρωση CO (ppm), την σχετική υγρασία (%RH), την θερμοκρασία (°C), τη ροή (ml/min), την τάση θερμαντήρα (V) και 14 αντιστάσεις (R1–R14). Η ανάγνωση έγινε με Spark DataFrame API.


1.2 Κανονικοποίηση του timestamp

Το αρχικό dataset ανακατασκευάστηκε ως start_ts + time_s, όπου start_ts εξάγεται από το filename (μορφή YYYYMMDD_HHMMSS). Αυτό έγινε επειδή το dataset περιλάμβανε δευτερόλεπτα από την αρχή του πειράματος και όχι το πλήρες time stamp. Στη συνέχεια έγινε ομαδοποίηση σε 5λεπτα bins (t5) και δημιουργήθηκε 'κοινή βάση' χρόνου ανά αισθητήρα μέσω μιας κανονικοποιημένης χρονοσειράς που ξεκινάει από 2025-09-01, με βήμα 5 λεπτών. Η υλοποίηση έγινε με row_number ανά sensor_id (idx) και μετατροπή σε timestamp_norm = start_unix + idx*300.


1.3 Έλεγχοι ποιότητας, ελλείπουσες τιμές και ακραίες τιμές

Έγινε έλεγχος για ελλείπουσες τιμές (NaN) και ακραίες τιμές (outliers) στα βασικά χαρακτηριστικά. Για ενδεικτική αντιμετώπιση outliers εφαρμόστηκε winsorization (clipping) σε ποσοστιαία όρια, ώστε να περιοριστούν εξαιρετικά ακραίες μετρήσεις χωρίς να χαθεί η χρονική συνέχεια.


1.4 Οπτικοποιήσεις κατανομών




Σχήμα: Διάγραμμα κουτιού (boxplot) της αντίστασης ανά αισθητήρα (5λεπτα bins).



Σχήμα: Ιστόγραμμα της συγκέντρωσης CO (*co_mean*).



Σχήμα: Ιστόγραμμα της μέσης θερμοκρασίας (*temp_mean*).



Σχήμα: Ιστόγραμμα της τάσης θερμαντήρα (*heater_v_mean*).

Τα παραπάνω σχήματα συνοψίζουν την κατανομή των μεταβλητών και αναδεικνύουν διαφορές κλίμακας και διασποράς ανά αισθητήρα.

1.5 Ανάλυση σε PySpark

Συνοπτικά ποσοτικά αποτελέσματα:

- i) Φίλτρο τάσης θερμαντήρα > 60% της μέγιστης και συνολική συγκέντρωση CO: 8,455,849.0534 ppm (άθροισμα).
- ii) Για κάθε αισθητήρα υπολογίστηκαν μέση τιμή και διακύμανση της αντίστασης (βλ. πίνακα αποτελεσμάτων στο notebook).
- iii) Accumulator: 302,529 εγγραφές ικανοποιούν CO>10 και RH<30 ($\approx 7.87\%$ επί $\sim 3,843,160$ γραμμών).
- iv) Υπολογισμός νέας αντίστασης $R = (5 - V) / V \times 1,000,000$ και επιστροφή $\max(R)$ ανά *heater_v* μέσω μείωσης βάσει κλειδιού.
- v) Για επιλεγμένο αισθητήρα εφαρμόστηκε παράθυρο 25 λεπτών (5 εγγραφές των 5 λεπτών) και υπολογίστηκαν *co_mean_25m* και *rh_mean_25m*.

2. Feature Engineering (pandas)


Στη συνέχεια, τα καθαρισμένα και κανονικοποιημένα δεδομένα μεταφέρθηκαν σε pandas DataFrame (pdf), όπου χρησιμοποιήθηκε ως index το timestamp_norm και ως στήλες τα υπόλοιπα χαρακτηριστικά (co_mean, rh_mean, temp_mean, flow_mean, heater_v_mean) καθώς και οι 14 αντιστάσεις.

2.1 Δημιουργία νέων χαρακτηριστικών

Δημιουργήθηκαν τα παρακάτω νέα contextual features:

- temp_diff: διαφορά θερμοκρασίας μεταξύ διαδοχικών χρονικών στιγμών (Δtemp).
- heater_phase: κατηγορική ετικέτα (low/high) ανάλογα με την τάση θερμοαντήρα.
- r_mean14: μέσος όρος των 14 αντιστάσεων ανά χρονικό βήμα.
- co_roll_25m: κυλιόμενος μέσος όρος 25 λεπτών (5 δείγματα) της συγκέντρωσης CO.
- r_std14 και n_sensors: τυπική απόκλιση αντιστάσεων και πλήθος διαθέσιμων αισθητήρων ανά χρονικό βήμα (για διαγνωστικούς ελέγχους).

2.2 Σχέση r_mean14 και co_roll_25m (25 λεπτά)




Σχήμα: Χρονική απεικόνιση: μ.ο. 14 αντιστάσεων (r_mean14) και κυλιόμενος μ.ο. 25 λεπτών της CO (co_roll_25m) σε ενδεικτικό τμήμα.

Το παραπάνω σχήμα απεικονίζει την εξέλιξη του μ.ο. των αισθητήρων (r_mean14) και ενός κυλιόμενου μ.ο. 25 λεπτών της CO.

3. Temporal Analysis

3.1 STL decomposition


Χρησιμοποιήθηκε Seasonal-Trend decomposition using LOESS (STL) στην χρονοσειρά r_mean14 . Επίσης, επιλέχθηκε περίοδος 12 δειγμάτων, άρα 60 λεπτών ($12 \cdot 5$ λεπτά), ως κατάλληλη περιοδικότητα που σχετίζεται με την θερμική διαμόρφωση.




Σχήμα: STL decomposition της χρονοσειράς r_mean14 : observed, trend, seasonal, residuals.

3.2 ACF / PACF στα υπολείμματα

Στην υπολειμματική συνιστώσα (residuals) υπολογίστηκαν ACF και PACF έως lag 144 (≈ 12 ώρες). Τα διαστήματα εμπιστοσύνης 95% παράγονται αυτόματα από τη statsmodels ($\alpha=0.05$), όπως συνηθίζεται σε εγχειρίδια χρονοσειρών.



Σχήμα: ACF της υπολειμματικής συνιστώσας (STL residuals) με 95% διαστήματα εμπιστοσύνης.



Σχήμα: PACF της υπολειμματικής συνιστώσας (STL residuals) με 95% διαστήματα εμπιστοσύνης.

3.3 Έλεγχος στασιμότητας (ADF)

Στα υπολείμματα του STL εφαρμόστηκε έλεγχος Augmented Dickey-Fuller (ADF). Τα αποτελέσματα ήταν τα εξής:

ADF statistic = -10.7654

p-value = 2.46e-19

Με το πόσο μικρό είναι το p-value μπορούμε εύκολα να απορρίψουμε την μηδενική υπόθεση ύπαρξης unit root. Επομένως τα υπολείμματα θεωρούνται στάσιμα.

4. Machine Learning Model Training

4.1 Διαχωρισμός δεδομένων

Στόχος είναι πρόβλεψη 1 βήματος ($t \rightarrow t+5$ λεπτά) της αντίστασης ανά αισθητήρα. Ο διαχωρισμός έγινε χρονικά σε train/validation/test με αναλογία 70%/20%/10% ώστε να αποφευχθεί διαρροή πληροφορίας από το μέλλον.

4.2 Spark MLlib μοντέλα (Linear Regression & Random Forest)

Εκπαιδεύτηκαν μοντέλα ανά αισθητήρα με Spark MLlib. Ως χαρακτηριστικά εισόδου χρησιμοποιήθηκαν τα contextual χαρακτηριστικά και τρέχουσες τιμές αντίστασης, ενώ ως στόχος χρησιμοποιήθηκε η επόμενη τιμή του εκάστοτε αισθητήρα (shift -1). Η αξιολόγηση έγινε με MAE, MAPE, RMSE, R^2 καθώς και με χρόνους εκπαίδευσης/πρόβλεψης.

Πίνακας 1 — Αποτελέσματα Linear Regression (Spark MLlib) ανά αισθητήρα

sensor_id	MAE	MAPE	RMSE	R2	train_s	infer_s
R1	0.871782	0.067782	1.190994	0.951369	1.679073	0.229877
R2	1.034831	0.072523	1.432858	0.941275	0.583017	0.128271
R3	1.235845	0.070173	1.692135	0.932827	0.557508	0.125007
R4	1.361843	0.089099	1.998897	0.912306	0.529743	0.133464
R5	1.795019	0.075549	2.636252	0.908967	0.515684	0.126996
R6	1.607203	0.073819	2.250515	0.927241	0.527152	0.117689
R7	1.751379	0.074504	2.544570	0.916651	0.494334	0.122999
R8	5.172878	0.243048	7.245086	0.530786	0.512537	0.125352
R9	5.148440	0.416175	7.396092	0.556470	0.526500	0.125404
R10	5.588157	0.275855	7.812526	0.499840	0.711030	0.179008
R11	4.702057	0.195350	6.746324	0.608583	0.650968	0.149920
R12	5.111158	0.264356	7.033153	0.491322	0.579099	0.140830
R13	4.455619	0.283329	6.345838	0.622791	0.631899	0.149548
R14	5.806146	0.258982	8.143303	0.553074	0.635819	0.151866


Πίνακας 2 — Αποτελέσματα Random Forest (Spark MLlib) ανά αισθητήρα

sensor_id	MAE	MAPE	RMSE	R2	train_s	infer_s
R1	1.061454	0.104968	1.499508	0.922911	29.532348	1.043408
R2	1.069228	0.094928	1.578367	0.928742	28.138276	0.939103
R3	1.357911	0.092999	1.935433	0.912122	29.096380	0.930393
R4	1.463485	0.101608	2.067753	0.906161	29.045408	0.926212
R5	2.077503	0.103407	3.138035	0.871015	27.619328	0.904635
R6	1.974613	0.111366	2.865801	0.882018	28.639634	0.921419
R7	2.187284	0.110462	3.260716	0.863134	28.500601	0.959368
R8	4.673014	0.233733	7.128976	0.545705	27.545155	0.933242
R9	4.890698	0.442166	7.530658	0.540183	26.391828	0.882766
R10	4.222325	0.212058	6.933619	0.606046	26.108242	1.035873
R11	3.599918	0.149791	6.109346	0.679008	26.597833	0.960079
R12	4.552739	0.251893	6.936288	0.505237	26.086397	0.860157
R13	4.351054	0.296239	6.572498	0.595364	25.745764	0.837405
R14	4.342038	0.200486	7.137405	0.656667	26.468911	0.852383


Πίνακας 3 — Σύνοψη (μέση τιμή $\pm$ τυπική απόκλιση) για LR και RF

sensor_id	lr mean	lr std	rf mean	rf std
MAE	3.260168	1.991778	2.987376	1.503048
MAPE	0.175753	0.114603	0.179007	0.101768
RMSE	4.604896	2.797515	4.621029	2.444516
R2	0.739536	0.198027	0.743880	0.166622
train_s	0.652454	0.302198	27.536865	1.297615
infer_s	0.143302	0.029828	0.927603	0.060947

4.3 Ενδεικτικές οπτικοποιήσεις (True vs Predicted)



Σχήμα: True vs Predicted (1-step) για R10 με Linear Regression (Spark MLlib).



Σχήμα: True vs Predicted (1-step) για R10 με Random Forest (Spark MLlib).

4.4 RNN μοντέλο (GRU)

Υλοποιήθηκε μοντέλο GRU σε περιβάλλον Keras για πολυέξοδη πρόβλεψη (14 outputs), δηλαδή ταυτόχρονη πρόβλεψη των 14 αντιστάσεων. Χρησιμοποιήθηκε ιστορικό 12 ωρών (seq_len=144 σε βήματα 5 λεπτών). Τα x και y κανονικοποιήθηκαν με StandardScaler. Αναφέρονται οι μετρικές ανά αισθητήρα καθώς και η συνολική εικόνα (mean±std).

Πίνακας 4 — Αποτελέσματα GRU (Keras) ανά αισθητήρα


sensor_id	MAE	MAPE	RMSE	R2
R1	1.237856	0.068979	1.643305	0.915196
R2	1.546995	0.075849	2.155116	0.901136

R3	1.915365	0.083260	2.484216	0.891674
R4	2.777973	0.119712	3.549937	0.745601
R5	2.962424	0.092388	3.606222	0.832241
R6	2.639810	0.091469	3.318073	0.851765
R7	2.795552	0.086572	3.434150	0.838468
R8	6.584186	0.247592	8.209953	0.366460
R9	7.216508	0.332073	8.805848	0.330839
R10	7.201144	0.338732	8.885296	0.392859
R11	7.195918	0.281387	8.952466	0.356285
R12	6.251543	0.265895	7.691104	0.353879
R13	6.519615	0.299724	8.033471	0.357461
R14	8.052533	0.323029	9.932305	0.355547

Πίνακας 5 — Σύνοψη GRU (mean $\pm$ std) στα 14 outputs

sensor_id	mean	std
MAE	4.635530	2.534904
MAPE	0.193333	0.112064
RMSE	5.764390	3.077378
R2	0.606386	0.259937

Χρόνοι GRU (ενδεικτικά από το πείραμα): train $\approx$ 24.26 s, inference $\approx$ 0.65 s (για το test set).



Σχήμα: True vs Predicted (1-step) για R10 με GRU (Keras).

4.5 Συζήτηση και σύγκριση

Τα μοντέλα Spark MLlib (LR/RF) έχουν γενικά χαμηλό χρόνο εκπαίδευσης και πρόβλεψης – κυρίως το LR – ενώ το RF χρειάζεται αρκετά περισσότερο χρόνο προκειμένου να τελειώσει η εκπαίδευσή του. Το GRU, ενώ έχει αρκετά μεγαλύτερο υπολογιστικό κόστος από τα άλλα 2, μοντελοποιεί ρητά χρονικό ιστορικό και προβλέπει και τις 14 αντιστάσεις ταυτόχρονα.

Μια παρατήρηση είναι ότι ορισμένοι αισθητήρες (R1-R7) πέτυχαν υψηλά R^2 , ενώ οι υπόλοιποι (R8-R14) είχαν σημαντικά χαμηλότερο R^2 , πράγμα που σημαίνει ότι η πρόβλεψή τους είναι αρκετά δυσκολότερη. Αυτό ίσως να συνδέεται με διαφορετική δυναμική, υψηλότερη μεταβλητότητα ή μη-γραμμικότητα σε αυτούς τους αισθητήρες.

Πατηρήσεις

Για ορισμένα σημεία του κώδικα χρησιμοποιήθηκε το Cursor, όμως μόνο για απλή συμπλήρωση και διευκόλυνση.

Στην τεχνική αναφορά χρησιμοποιήθηκε AI για την εύκολη παραγωγή των πινάκων με τα δεδομένα και για το outline της εργασίας.